◆ PROJECT / LOGSENTINEL

실시간 로그 이상(Anomaly) 탐지

비지도 학습(Isolation Forest)과 딥러닝(LSTM)을 결합한
백엔드 시스템 로그 하이브리드 분석 엔진

PILLAR 01	PILLAR 02	PILLAR 03
NLP 전처리 & 500차원 벡터화	**하이브리드 ML × DL 아키텍처**	**불균형 데이터 정직한 평가**
Regex 일반화 + TF-IDF	Isolation Forest → LSTM	Weighted Loss + F1 0.914

발표자 · **박진우 (Joshua)** · 2026 수도권ICT 인공지능 언어 마스터과정 B반

---

§ 02 / ARCHITECTURE

NLP 전처리부터 FastAPI 서빙까지, 3-Stage 파이프라인

STAGE 01 · NLP
텍스트 정제 + 벡터화
Regex로 IP / HEX / TIME 일반화 →
TF-IDF로 500차원 수치 벡터

→

STAGE 02 · ML
Isolation Forest
라벨 없이 이상치 1차 필터링,
임계값 `THRESHOLD = 0.210`

→

STAGE 03 · DL
PyTorch LSTM
최근 5개 로그 시퀀스로
장애 등급 다중 분류

- 🟢 Score ≥ 0.210 → 즉시 NORMAL 응답 (연산 자원 보존)
- 🔴 Score < 0.210 → Stage 3 딥러닝 정밀 분석 투입

KEY OUTCOMES

0.914	500	5	3
검증 F1-Score (클래스 불균형 극복)	TF-IDF 벡터 차원 (어휘 사전 크기)	LSTM 시퀀스 길이 (슬라이딩 윈도우)	분류 클래스 ALERT · FATAL · WARNING

Ref: Liu et al. (2008) Isolation Forest · Hochreiter & Schmidhuber (1997) LSTM

---

§ 03 / FUTURE WORK

LSTM을 넘어, AIOps 고도화의 다음 이정표

01
NLP 고도화
Transformer · Attention 도입

TF-IDF는 단어 순서와 의미 유사성을 완벽히 포착하기 힘듦.

BERT 및 **LogBERT** 기반 자기지도학습을 도입해 로그 의미론적 맥락 파악을 극대화.

02
XAI · 설명 가능성
SHAP · LIME으로 판단 근거 시각화

서버 엔지니어에게 "장애 발생" 예측 알림만 주지 않음.

"왜 이 로그 패턴이 이상치인지" 단어별 영향도를 시각화하여 신뢰성 있는 인프라 제어 지원.

03
분산 · 인프라 · 통합
Kafka · Spark 실시간 스트림

단일 파일 서버 형태를 넘어서, **Apache Kafka** 스트림과 **Apache Spark** 분산 아키텍처 결합.

대규모 엔터프라이즈 환경에서의 최적화 설계 목표.

---

§ 04 / BUSINESS VALUE

예측되지 않는 시스템 장애는 없다 — AIOps 기반 상업화 시나리오

A	SAAS **LogSentinel Cloud** B2B · 구독 과금	스타트업·소규모 개발사가 자사 서버 로그 스트림을 API에 연동만 하면, 대시보드를 통해 실시간 이상 점수(Anomaly Score)와 장애 전조 증상을 관측할 수 있는 **구독형 SaaS** 모델.
B	AUTO-HEALING **알람 + 플레이북 자동 트리거** Ansible · K8s self-heal	슬랙 메시지에 그치지 않고, 분류 등급(ALERT·FATAL)에 따라 사전 정의된 복구 스크립트를 자동 실행하는 **장애 자가 치유 패키지** 상품.
C	LICENSING **지능형 플러그인 제공** Datadog · Grafana	이미 업계 표준인 모니터링 도구에 'LogSentinel AI 엔진'을 API 플러그인 형태로 이식, 룰 기반 탐지를 지능화해주는 **B2B 라이선스** 비즈니스 모델.

---

§ 05 / ACKNOWLEDGEMENT

감사합니다.

01. 2026 수도권ICT 인공지능 언어 마스터과정 B반을 성심성의껏 이끌어 주시며, 생초보 개발자였던 저에게 **데이터 분석과 딥러닝의 새로운 지평**을 열어주신 강사님과 멘토님들께 진심으로 감사드립니다.

02. 막히는 구현 과정마다 **현업의 생생한 조언과 통계적 접근법**을 일깨워주시고, 아낌없이 격려해주신 헌신에 깊은 존경을 표합니다.

03. 최적의 교육 환경과 인프라를 마련해주신 **모든 교육 운영진**의 노고에 진심 어린 감사를 전합니다.

— **박진우 (Joshua)**, 2026 ICT 언어B

◆ APPENDIX · ANTICIPATED QUESTIONS

예상 질문 해설집

NLP 전처리부터 평가지표까지 — 발표 중 발생할 수 있는 5가지 핵심 질문에 대한 상세 해설.

Q1. Regex & TF-IDF 벡터화 · Q2. Isolation Forest Score & Contamination · Q3. LSTM 시계열 분류
Q4. Weighted Cross Entropy Loss · Q5. F1-Score & Confusion Matrix

---

APPENDIX · Q1 / NLP PREPROCESSING

Q1. 텍스트 로그가 어떻게 수치 벡터로 변환되는지 예시를 보여주세요.

STEP 01 · REGEX 일반화 (노이즈 정제)
실행시마다 가변적인 요소(날짜, IP, HEX 코드)를 정규식으로 정형 태그 변환합니다.

ORIGINAL RAW LOG
```
"2026-06-22 19:15:14 Core_0 link down: exception 0x4f3a at node 192.168.1.10"
```

↓

NORMALIZED TEMPLATE
```
"Core_0 link down: exception [HEX] at node [IP]"
```

STEP 02 · TF-IDF 벡터화 (500차원 중요도 매핑)
어휘 단어 사전(Vocabulary) 인덱스에 따라 TF(빈도)와 IDF(독특함 가중치)를 곱해 벡터를 생성합니다.

VOCABULARY INDEX
```
[ 0: 'link', 1: 'down', 2: 'exception', 3: '[IP]', ... 499: 'unknown' ]
```

OUTPUT VECTOR ($\mathbb{R}^{500}$)
```
[ 0.45, 0.45, 0.62, 0.0, 0.15, 0.0, ..., 0.0 ]
```

- ● **vec[2] = 0.62:** 이 로그에서 `exception` 단어가 갖는 독특한 중요도 점수.
- ● vec[3] = 0.00: 현재 로그에 `[IP]` 태그 단어가 나타나지 않았음을 표시.

TF (TERM FREQUENCY)
개별 로그 내에서 특정 단어가 등장한 빈도수 (수치가 클수록 중요)

IDF (INVERSE DOCUMENT FREQUENCY)
전체 로그 뭉치에서 해당 단어가 얼마나 희소한가 (흔할수록 가중치 축소)

APPENDIX · Q2 / ISOLATION FOREST

Q2. 라벨이 없는 데이터에서 어떻게 정상과 이상을 구분하며, 오염도(Contamination)와 스코어의 관계는 무엇입니까?

CONCEPT 01
의사결정 분할을 통한 고립 (Isolation)

정상 데이터는 오밀조밀 모여있어 이를 개별 분리하기 위해 트리 깊이가 매우 깊어집니다.

반면 **이상 데이터는 멀리 혼자 고립**되어 있으므로 몇 번의 무작위 분할(짧은 깊이)만으로 고립됩니다.

CONCEPT 02
고립도 스코어 계산

무작위로 생성한 100개 나무들의 평균 경로 길이를 0~1 범위 점수로 환산합니다.

경로 길이가 짧고 빨리 고립될수록 점수가 낮아지며(scikit-learn decision_function 기준), 점수가 낮을수록 **이상치(Anomaly)**로 취급합니다.

CONCEPT 03
오염도 (Contamination)

전체 훈련 데이터 중 **이상치가 대략 몇 % 섞여 있을 것인가** 에 대한 학습 가이드라인 비율입니다.

예를 들어 `0.05` 로 지정하면 모델은 경로가 가장 짧은 상위 5%를 이상치로 보고 정상 임계치 경계선을 스스로 결정합니다.

본 프로젝트에서는 최적 임계치 scan을 통해 Anomaly THRESHOLD를 0.210으로 조율하여 F1-Score 0.914를 달성했습니다.

APPENDIX · Q3 / PYTORCH LSTM

Q3. 딥러닝 다중 분류 모델인 LSTM의 구조와 시계열 분석적 의의를 설명해주세요.

시계열 분석(TIME-SERIES) 관점의 의의

시스템 장애는 단일 로그 1건만으로 갑자기 튀어나오지 않습니다.

장애가 터지기 전 수 초~수 분 전부터 특정 경고 로그들이 **순차적이고 유기적인 시퀀스 흐름**을 타며 발생합니다.

LSTM은 과거 시점의 상태(Hidden State, Cell State) 정보를 망각/유지 게이트를 통해 메모리에 기억하므로, 이러한 **로그들의 시계열적 선후 관계와 전조 증상 흐름**을 잡아낼 수 있습니다.

입출력 텐서 규격 & SOFTMAX

INPUT TENSOR SHAPE
```
[Batch_size=1, Seq_len=5, Input_dim=500]
```
최근 수집된 연속 5개 로그 시퀀스(각 500차원 벡터)가 입력됨.

OUTPUT TENSOR (LOGITS)
```
[1, Num_classes=3] → 예: [2.54, -1.21, 0.45]
```
ALERT, FATAL, WARNING에 대한 비정규화 점수.

SOFTMAX PROBABILITY MAPPING
```
Softmax([2.54, -1.21, 0.45]) = [0.89, 0.02, 0.09]
```
각 등급별 발생 확률로 매핑(합=1.0). 가장 높은 확률(89%)의 인덱스를 최종 장애 등급(ALERT)으로 예측하고, 이때의 확률을 신뢰도(Confidence)로 표기.

APPENDIX · Q4 / WEIGHTED CE LOSS

Q4. 가중 손실 함수(Weighted Cross Entropy Loss)란 무엇이며, 왜 사용합니까? 예시와 함께 설명해주세요.

WHAT & WHY (개념 및 도입 목적)

● **무엇인가 (What):** 각 클래스별 오차(Loss)에 가중치(Class Weight)를 다르게 주어 합산하는 특수 손실 함수입니다. 데이터 수량이 극도로 적은 희귀 클래스를 틀렸을 때 벌점을 극대화시킵니다.

● **왜 쓰는가 (Why):** 99% 정상 데이터에서 일반 Loss를 쓰면, 모델은 학습이 덜 되더라도 무조건 '정상'으로 예측하려고만 합니다. 손실 함수가 '정상'을 틀렸을 때보다 '장애'를 틀렸을 때의 페널티를 거대하게 설정하여, 모델이 소수 장애 패턴의 특징을 열심히 훈련하도록 강제합니다.

● **언제 쓰는가 (When):** 실제 인프라 로그처럼 특정 범주(정상)에 압도적으로 치우쳐진 **극심한 클래스 불균형(Class Imbalance)** 상황.

CONCRETE EXAMPLE · 직관적 예시

상황: 정상 로그 99,000건, 에러 로그(FATAL) 1,000건인 경우 (99:1 비율).

1) 일반 CE Loss 적용 시: - 모델이 게으르게 10만 건 모두 "정상"으로 찍으면 정확도는 99%입니다. - 1,000건(에러)만 틀렸으므로 Loss 합산치도 매우 작아 모델은 성능 튜닝을 중단합니다.

2) Weighted CE Loss 적용 시 (에러 오답 가중치 99배 부여): - 모델이 에러 1,000건을 '정상'이라고 잘못 예측하면 감점(오차)이 $1,000 \times 99 = 99,000$점으로 확대됩니다. - 모델 입장에서는 어설프게 정상으로 몰아서 찍었다가는 거대한 오차 폭탄을 맞으므로, 단 1,000건에 불과한 에러 로그의 패턴 특징을 눈에 불을 켜고 파악하게 됩니다.

APPENDIX · Q5 / CONFUSION MATRIX & F1-SCORE

Q5. 정확도가 99%인 모델이 98%인 모델보다 구릴 수 있나요? 혼동 행렬과 F1-Score 수식을 사용해 설명해주세요.

모델 A: 무조건 정상 판정 (정확도 위주)

100개 데이터(정상 99개, 실제 장애 1개)를 몽땅 정상으로 대답함.

실제 \ 예측	예측: 장애	예측: 정상
실제: 장애	TP = 0	**FN = 1 (미탐)**
실제: 정상	FP = 0	**TN = 99**

정확도(Accuracy) = 99% $\frac{0+99}{100}$
정밀도(Precision) = 0% | 재현율(Recall) = 0%
F1-Score = 0% (장애 감지력 제로의 무용지물 모델)

모델 B: 장애 검출 및 정상 2개 오탐 (균형 위주)

예측한 3개 중 진짜 장애 1개 존재, 2개는 정상인데 오판(오탐).

실제 \ 예측	예측: 장애	예측: 정상
실제: 장애	**TP = 1**	FN = 0
실제: 정상	**FP = 2 (오탐)**	TN = 97

정확도(Accuracy) = 98% $\frac{1+97}{100}$
정밀도(Precision) = 33.3% $\frac{1}{1+2}$ | 재현율(Recall) = 100% $\frac{1}{1+0}$
F1-Score = 50% $2 \times \frac{0.333 \times 1.0}{0.333 + 1.0}$ (실속 있는 우수한 모델)

PRECISION (정밀도)	RECALL (재현율)	F1-SCORE
$\frac{TP}{TP+FP}$	$\frac{TP}{TP+FN}$	$2 \times \frac{Precision \times Recall}{Precision + Recall}$
장애라고 알람을 보낸 것 중 진짜 장애 비율 (오탐 방지)	실제 발생한 전체 장애 중 찾아낸 비율 (미탐 방지)	정밀도와 재현율의 조화 평균 (불균형 데이터 왜곡 보정)

Use Space / ↓ / → for Next, ↑ / ← for Prev

◀ PREV 01 / 11 NEXT ▶